

量化专题报告

基于深度学习的指数增强策略

低频因子模型的挑战

基本面因子是低频多因子模型的重要 alpha 来源，然而我们发现 2021 年以来业绩类因子出现普遍性的大面积回撤。对此，我们曾经提出过三个维度的应对方案：深入基本面、拥抱 beta 以及量价+AI。

前两者基于逻辑驱动，依托于投资人对于财务、宏观风格的深入理解，我们曾做过深入覆盖。而量价+AI 基于数据驱动，从模型层面捕捉市场短期的定价不充分，我们在本篇报告中展开初步探索。

深度学习模型与特征构建

金融数据具有显著的时序关联性，而深度学习中 RNN 类模型对于时序数据的建模表现最为亮眼。我们认为模型绩效的提升可以从三个维度入手：

1. 通过调整超参数选取、label 构建、数据预处理方式等精进单一模型；
2. 对同一数据集根据不同模型训练，堆叠多模型的输出；
3. 对同一模型构建差异化数据集输入，堆叠多数据集的输出；

基于 RNN 类模型中的 LSTM，我们以第三个维度为切入点，希望通过构建差异化的数据集作为模型输入，捕捉具有增量性的信息。

深度学习选股因子

通过构建 6 个不同的数据集，我们训练了 6 个深度学习指标，综合 6 个指标后的深度学习因子绩效良好。2017 年以来多空年化收益 100.8%，多头超额收益 38.2%，因子 IC 均值 12.7%，ICIR 达到 1.23。

基于深度学习模型的指数增强策略

基于深度学习因子我们构建周度调仓的中证 500/1000 指数增强组合：

1. 中证 500 指数增强组合 2017 年以来，组合年化收益 15.4%，超额中证 500 指数 17.1%，跟踪误差 5.7%，信息比率 2.84。
2. 中证 1000 指数增强组合 2017 年以来，组合年化收益 19.4%，超额中证 1000 指数 24.6%，跟踪误差 5.7%，信息比率 4.04。

风险提示：结论基于历史数据以及模型推算，存在失效风险。

作者

分析师 缪铃凯

执业证书编号：S0680521120003

邮箱：miaolinkai@gszq.com

分析师 刘富兵

执业证书编号：S0680518030007

邮箱：liufubing@gszq.com

相关研究

1、《量化分析报告：从 A+H 核心资产中掘金——中银

MSCI 中国 A50 互联互通指数增强基金投资价值分析》

2023-11-05

2、《量化周报：市场或将继续反弹》2023-11-05

3、《量化分析报告：择时雷达六面图：本期打分无变化》

2023-11-04

4、《量化点评报告：十一月配置建议：如何对红利风格

进行择时？——资产配置思考系列之四十七》2023-

11-02

5、《量化分析报告：“机器替人”大势所趋，机器人产

业进程加速——国泰中证机器人 ETF 投资价值分析》

2023-10-31

内容目录

一、低频因子模型的挑战	4
二、深度学习模型与特征构建	6
三、深度学习选股因子	9
3.1 低频行情数据集	9
3.2 日内行情数据集	10
3.3 其他衍生数据集合	11
3.4 综合因子 nn_score	12
四、基于深度学习模型的指数增强策略	14
4.1 中证 500 指数增强	14
4.2 中证 1000 指数增强	15
五、总结	16
风险提示	17

图表目录

图表 1: 基本面因子 2021 年以来绩效	4
图表 2: 价值/成长与公募机构资金流入相关性	4
图表 3: 政府补助因子绩效	5
图表 4: 小盘价值组合分年收益	5
图表 5: 因子模型框架	6
图表 6: RNN 网络结构	6
图表 7: RNN 模型输入	7
图表 8: 模型训练流程图	8
图表 9: bar_daily 因子分年绩效	9
图表 10: bar_daily 因子多头超额累计	9
图表 11: bar_weekly 因子分年绩效	9
图表 12: bar_weekly 因子多头超额累计	9
图表 13: bar_minutely 因子分年绩效	10
图表 14: bar_minutely 因子多头超额累计	10
图表 15: intra_return 因子分年绩效	10
图表 16: intra_return 因子多头超额累计	10
图表 17: money_flow 因子分年绩效	11
图表 18: money_flow 因子多头超额累计	11
图表 19: pv_factor 因子分年绩效	11
图表 20: pv_factor 因子多头超额累计	11
图表 21: 因子截面相关性矩阵图	12
图表 22: 综合因子分年绩效	12
图表 23: 综合因子多头超额累计	12
图表 24: 不同预测区间下综合因子绩效	13
图表 25: 综合因子预测能力衰减	13
图表 26: 不同指数成分股中因子 ic	13
图表 27: 综合因子与常用指标相关性	13
图表 28: 中证 500 指数增强组合净值	14

图表 29: 中证 500 指数增强组合分年绩效.....	14
图表 30: 中证 1000 指数增强组合净值.....	15
图表 31: 中证 1000 指数增强组合分年绩效.....	15

一、低频因子模型的挑战

基本面因子是低频多因子模型的重要 alpha 来源，然而我们发现 2021 年开始业绩类因子普遍出现大规模的回撤。其中盈利、成长、预期调升类因子失效最为明显，多头回撤显著，这种现象在中证 800 指数成分股中更为强烈。

图表 1: 基本面因子 2021 年以来绩效

因子简称	因子	中证800				wind全A			
		多头-2021年以来	ic-2021年以来	多头-2023年以来	ic-2023年以来	多头-2021年以来	ic-2021年以来	多头-2023年以来	ic-2023年以来
EarningsUpRatio	财报超预期幅度	-1.7%	-0.3%	-7.1%	-0.2%	-1.4%	1.1%	-9.5%	0.4%
EarningsUpNum	分析师预期调升幅度	-0.8%	-1.4%	4.0%	-2.8%	-7.0%	4.5%	-14.0%	4.8%
ROE	净资产收益率	0.2%	-1.0%	0.7%	-2.1%	0.0%	2.8%	-3.1%	4.7%
ROA	总资产收益率	0.8%	-1.3%	2.2%	-2.1%	0.2%	2.3%	0.6%	4.5%
dROE	roe同比变化	-6.1%	1.4%	-7.9%	1.1%	2.3%	3.0%	-0.6%	3.8%
dROA	roa同比变化	-6.9%	1.0%	-9.1%	0.7%	1.7%	2.7%	-0.3%	3.4%
profitYOY	净利润增速	-0.5%	0.7%	-4.7%	-1.7%	5.7%	2.3%	3.6%	2.6%
saleYOY	营收增速	-5.1%	-0.9%	-2.0%	-3.5%	-1.5%	0.8%	-5.8%	-0.5%
TotProfitYOY	总利润增速	-2.8%	-0.2%	-4.7%	-2.5%	1.1%	1.6%	0.7%	1.7%
SUE	SUE	-1.6%	1.8%	-7.3%	-0.1%	6.1%	2.1%	0.6%	2.3%
SUR	SUR	-2.4%	0.4%	-5.2%	0.1%	5.0%	1.3%	-3.9%	0.1%
BP	市净率倒数	15.2%	7.9%	20.0%	15.3%	7.8%	7.1%	5.8%	10.9%
EP	市盈率倒数	5.3%	5.8%	12.0%	9.6%	11.5%	5.9%	12.5%	9.3%
SP	市销率倒数	4.6%	5.3%	12.4%	10.8%	7.9%	5.2%	4.4%	7.4%
HoldRatio	公募基金平均持股权重	3.3%	-0.8%	7.9%	1.1%	-4.5%	2.3%	-6.0%	-1.0%


资料来源: wind, 国盛证券研究所

关于业绩类因子的回撤是短期现象还是长期持续，众说纷纭。风格呈现出周期性波动，而基本面因子在长期虽有 alpha，但短期更像是 beta，其绩效受到众多因素的影响。

例如，机构资金流入与价值、成长风格绩效呈现出明显相关性。主动权益基金规模环比增速与当季成长因子(dROE)多头超额收益表现出明显正相关，序列相关性达到 32.8%，而其与估值因子(BP)多头超额收益序列相关性则为-17.8%。

因此，我们相信长期而言业绩类因子终将回归，那么短期我们可以做些什么应对？

图表 2: 价值/成长与公募机构资金流入相关性



资料来源: wind, 国盛证券研究所

关于业绩类因子的失效，我们曾经提出过三个维度的应对方案：

1. 深入基本面：在基本面数据中挖掘仍未失效的 α ；
2. 拥抱 β ：在组合维度应用行业轮动、主动量化等策略；
3. 量价+AI：提高换手，运用机器学习、深度学习捕捉短期的量价信息；

图表 3：政府补助因子绩效

年份	多空收益	多头超额	IC均值	ICIR	IC胜率
2011	7.0%	3.1%	2.1%	2.18	66.7%
2012	15.8%	9.2%	3.6%	2.80	83.3%
2013	7.6%	-2.9%	4.7%	5.12	100.0%
2014	17.2%	11.2%	2.7%	2.17	75.0%
2015	8.1%	6.6%	2.8%	1.96	66.7%
2016	11.8%	9.9%	5.4%	3.50	91.7%
2017	28.1%	14.5%	7.6%	7.62	100.0%
2018	12.4%	7.1%	5.8%	4.04	91.7%
2019	28.7%	15.9%	6.6%	2.67	83.3%
2020	29.0%	8.7%	6.5%	5.21	100.0%
2021	10.7%	9.0%	3.8%	2.74	83.3%
2022	11.5%	10.8%	3.2%	2.46	75.0%
20230928	18.0%	9.9%	6.5%	5.32	88.9%
全样本	16.5%	9.0%	4.7%	3.28	85.0%

资料来源：wind，国盛证券研究所

图表 4：小盘价值组合分年收益

年份	组合收益	国证2000 指数	年化超额	信息比率	最大回撤	超额回撤
2012	23.6%	0.8%	22.9%	4.43	-20.0%	-2.0%
2013	51.0%	33.3%	17.7%	2.15	-16.6%	-2.7%
2014	61.6%	42.4%	19.2%	2.08	-8.5%	-5.7%
2015	139.9%	88.1%	51.8%	2.40	-48.7%	-14.9%
2016	11.3%	-12.1%	23.5%	4.45	-25.0%	-1.9%
2017	-5.2%	-16.9%	11.7%	3.67	-15.2%	-1.6%
2018	-20.0%	-33.8%	13.7%	4.11	-30.3%	-1.7%
2019	38.2%	23.4%	14.7%	1.88	-18.3%	-6.5%
2020	44.6%	16.9%	27.7%	2.50	-13.5%	-7.2%
2021	43.0%	29.2%	13.8%	0.87	-13.3%	-12.0%
2022	14.9%	-17.2%	32.1%	3.33	-17.1%	-7.3%
20230928	21.1%	-0.1%	21.1%	2.69	-7.5%	-5.1%
全样本	32.5%	9.1%	23.4%	2.57	-48.7%	-14.9%

资料来源：wind，国盛证券研究所

关于前两个维度，在以往的报告中我们有所涉及：

关于深入基本面，我们在前期报告中提出基于财报中的政府补助信息构建的政府补助因子，其可以作为盈利类因子的优秀辅助。政府补助因子 GovtSubsidy 与 ROE 因子的截面相关性接近 50%，但是在盈利类因子多头普遍失效的情形下，GovtSubsidy 因子多头在近 3 年均保持每年约 10% 的年超额收益。

因此，我们相信基本面信息中仍然存在有效的 α 信息，但是对于这些信息的挖掘需要深入财报、对基本面有深刻理解，寻找增量的信息具有较高的难度。

关于拥抱 β ，在对应的市场风格下一些 smart β 类的主动量化策略能取得亮眼的收益表现。我们跟踪的小盘价值组合历经 1 年多的样本外跟踪，今年以来截至 20230928 日，组合取得绝对收益 21.1%，超额国证 2000 指数 21.1%，超额显著。

但是，拥抱 β 需要我们对于市场风格具有一定的敏感性，在对应的市场状态下配置可行的主动量化策略，而对于风格的判断从来都不是一件简单的事情。

关于量价+AI，与前两者最大的差异点在于我们将获取超额收益的方式从理解市场、理解基本面切换到了数据建模层面。随着算力的发展与技术的进步，深度学习模型已经从传统的统计学中脱离，我们不再追求逻辑层面的可解释性，基于数据建模分析维度同样也能捕获到金融市场中短期的定价不足。


本文，我们将对于第三个维度“量价+AI”展开初步的探索，希望补充基本面模型对于市场短期 α 捕捉的不足。

二、深度学习模型与特征构建

基于多因子模型的框架，我们通常构建因子预测股票截面收益，进而通过组合优化得到股票持仓，在此机器学习/深度学习与传统框架契合。

传统选股因子来源于手工构建的基本面或者交易指标等，而机器学习/深度学习算法则能自动化搜索挖掘有效信号。区别于基本面特征更多的基于逻辑驱动，对于量价特征我们可以利用各类算法基于数据驱动挖掘增量信息。


图表 5: 因子模型框架



资料来源：国盛证券研究所

对于“数据->特征->因子”模式，通常数据源最为关键，其次是特征设计，模型的重要性则要弱于前两者。完成数据准备和特征构建后，遗传规划、神经网络等经典算法可以帮助我们挖掘一些有效信号。

图表 6: RNN 网络结构



资料来源：国盛证券研究所

金融数据具有明显的时序特征，深度学习模型中的 RNN 模型，在基于时序信息建模中表现出优异效果，RNN 模型的基本结构如下：

输入: $input = (x_1, x_2, \dots, x_T)$, 其中 $x_t = (x_{t,1}, x_{t,2}, \dots, x_{t,m})$, m 为特征数, T 为序列长度;

隐藏层: $s_t = f(U * x_t + W * s_{t-1})$

输出层: $o_t = g(V * s_t)$

损失函数: $loss = criterion(o, label)$

利用 $loss$ 度量预测值和真实值之间的误差，根据误差反向传播，训练参数矩阵 U, W, V 。

由于 RNN 面对长序列数据存在梯度消失等缺陷，因此在 RNN 基础上衍生出了 LSTM、GRU 等模型。本文以 LSTM 为例，探索深度学习模型对于股票时序数据中的 alpha 信息捕捉。

首先，以往我们在线性模型中的输入特征向量通常为因子截面取值 $(a_1, a_2, \dots, a_n)$ ，通过因子加权，得到股票收益预测/因子，输入样本为一维数据：


$$\sum_i w_i * a_i$$

相比而言，RNN 的输入刻画了特征的时序变化，其包含特征间的截面关系以及特征自身的时序关系两维度信息，输入样本为二维数据矩阵：

$$x = \begin{pmatrix} a_{1,1} & \cdots & a_{1,m} \\ \vdots & \ddots & \vdots \\ a_{t,1} & \cdots & a_{t,m} \end{pmatrix}$$

模型经过计算之后得到股票收益预测/因子得分 $f(x)$ 。

图表 7: RNN 模型输入



资料来源：国盛证券研究所

此外，近年来 transformer 在自然语言学习等领域展现出良好表现，其核心在于注意力机制的引入。因此，在 LSTM 基础上，我们在隐藏层后设计了一个简易自注意力机制。

假设 hidden 为序列的隐藏层，我们通过线性层提取 Q、K、V 矩阵：

$$Q = \text{linear_q}(\text{hidden}[-1])$$

$$K = \text{linear_k}(\text{hidden})$$

$$V = \text{hidden}$$

$$\text{att} = \text{softmax}(Q * K^T / \sqrt{d_k}) * V$$

$$\text{output} = \text{sigmoid}(\text{linear_c}(\text{hidden}[-1], \text{att}))$$

将输出 output 进行截面 zscore 标准化后，接入权重恒为 1 的线性层转换为因子值：


$$\text{score} = \text{zscore}(\text{output}) \times \vec{1}$$

利用 score 作为最终的因子值，以上则为本文所设计的模型结构。

最后，具体训练模型时，考虑到模型输出信号的可交易性，我们以股票 T+1 至 T+11 的 vwap 价格计算的收益率为预测目标：

1. 模型每年滚动训练，在每年年初以股票过去 8 年的历史数据为数据集，按照时间先后，拆分后 10% 数据作为验证集，其余为训练集；
2. 我们假设在不同日期的股票样本是有差异的，即训练时每个 batch 的 input 为 T 日所有股票样本；
3. 预测目标 label 为股票收益率对行业、市值回归之后的残差 zscore 值；
4. 损失函数 loss 定义为 pred 与 label 之间的 pearson correlation；
5. 采取 early stop 机制防止训练过拟合，验证集 loss 多次不下降时停止训练，返回验证效果最好的参数组合；

图表 8：模型训练流程图



资料来源：国盛证券研究所

而对于模型绩效的提升，一般通过几个维度展开：

1. 通过调整超参数选取、label 构建、数据预处理方式等精进单一模型；
2. 对同一数据集根据不同模型训练，堆叠多模型的输出；
3. 对同一模型构建差异化数据集输入，堆叠多数据集的输出；

本文将探索第三个维度，尝试构建不同数据集提取不同是 alpha 信息。我们基于端到端建模最常用的是股票的日行情数据，日级别的价格和成交额、量等信息。

微观角度看，日行情特征集合是股票高频逐笔交易数据根据成交的价/量信息降频后衍生出的日频特征。按照这个思路，我们可以把特征工程建立在从高频数据中降频生成类似的特征集合。

日/周/分钟频率行情数据集合：价格的开、高、低、收、成交额/量等。

资金流特征集合：逐笔成交数据根据订单的金额大小拆分，衍生得到日频率资金流特征：特大、大、中、小单买入/卖出金额。

日内收益特征集合：日内数据按照 30 分钟窗口拆分，可以得到区间收益的开高低收分布：开盘收益率、早盘收益率、尾盘收益率、最高收益率、最低收益率、平均收益率。

由于训练具有随机性，不同随机数种子训练出的模型结果存在差异。分析表明，相同模型下堆叠不同随机数种子训练出的结果可以提升模型绩效。但是，受限于算力限制，本文所有结果均在 CPU 上训练、推理，因此我们只展示根据单一随机数种子训练的结果。

因子检验时，我们计算 T 日因子对于 T+1 至 T+6 日 vwap 价格计算的收益的预测能力，即检验因子对于周度窗口的预测有效性，并展示因子 20 分组多头的扣费前超额收益。

三、深度学习选股因子

3.1 低频行情数据集

数据集:

股票日行情 *bar_daily*、周行情 *bar_weekly*

数据特征:

开盘价、最高价、最低价、收盘价、均价、5/10/20 日均线、成交量、成交额;

数据预处理:

1. 数据滚动 30 日窗口取数据构建数据集, 数据序列长度为 30;
2. 价格数据先除以最新收盘价标准化, 而后整体在面板上 zscore;
3. 成交量/额数据除以序列均值标准化, 而后单独在面板上取 zscore;


日线因子 *bar_daily* 在 2017 年以来多空年化收益 91.7%, 多头超额收益 33.6%, 因子 IC 均值 10.7%, IC 周度胜率为 84.7%, ICIR 为 1.00。

图表 9: *bar_daily* 因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	75.7%	31.9%	11.2%	77.8%	0.80
2018	92.4%	46.9%	14.4%	92.6%	1.41
2019	105.1%	30.5%	11.3%	88.1%	1.18
2020	103.4%	39.2%	10.5%	88.9%	1.13
2021	89.0%	25.2%	8.4%	82.7%	0.94
2022	76.2%	21.8%	9.3%	82.6%	0.93
20230928	60.8%	17.2%	9.2%	78.5%	0.84
period	91.7%	33.6%	10.7%	84.7%	1.00

资料来源: wind, 国盛证券研究所

图表 10: *bar_daily* 因子多头超额累计



资料来源: wind, 国盛证券研究所


周线因子 *bar_weekly* 在 2017 年以来多空年化收益 85.4%, 多头超额收益 31.6%, 因子 IC 均值 10.4%, IC 周度胜率为 85.7%, ICIR 为 1.01。

图表 11: *bar_weekly* 因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	69.2%	31.5%	10.9%	84.5%	1.02
2018	96.1%	54.3%	14.9%	95.9%	1.59
2019	104.5%	31.3%	11.0%	83.2%	0.95
2020	83.9%	25.7%	10.1%	84.0%	0.94
2021	83.6%	23.8%	7.6%	86.0%	0.93
2022	75.5%	23.7%	9.1%	86.8%	1.10
20230928	46.4%	8.3%	9.2%	77.3%	0.78
period	85.4%	31.6%	10.4%	85.7%	1.01

资料来源: wind, 国盛证券研究所

图表 12: *bar_weekly* 因子多头超额累计



资料来源: wind, 国盛证券研究所

3.2 日内行情数据集

数据集:

股票日内行情`bar_minutely`、日内收益分布`intra_return`:

数据特征:

`bar_minutely`: 开盘价、最高价、最低价、收盘价、均价、成交量、成交额;

`intra_return` 股票日开盘收益率、早盘 30 分钟收益率、日内最高收益率、日内最低收益率、尾盘 30 分钟收益率、日内平均收益率;

数据预处理:

1. 30 分钟 K 线滚动 5 日窗口取数据构建数据集, 数据序列长度为 40, 价格和成交量数据特征标准化方式与 3.1 中一致;
2. `intra_return` 数据集中 6 个收益率特征一起面板上 zscore;


分钟线因子`bar_minutely`在 2017 年以来多空年化收益 84.9%, 多头超额收益 28.3%, 因子 IC 均值 10.7%, IC 周度胜率为 88.2%, ICIR 为 1.13。

图表 13: `bar_minutely` 因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	65.3%	22.4%	11.3%	88.7%	1.16
2018	80.6%	36.3%	13.8%	95.1%	1.70
2019	111.4%	34.2%	12.3%	90.6%	1.25
2020	102.0%	38.7%	10.0%	91.0%	1.16
2021	75.4%	17.7%	6.8%	79.8%	0.85
2022	73.2%	20.6%	10.3%	88.8%	1.18
20230928	53.2%	12.2%	10.0%	81.7%	0.87
period	84.9%	28.3%	10.7%	88.2%	1.13

资料来源: wind, 国盛证券研究所

图表 14: `bar_minutely` 因子多头超额累计



资料来源: wind, 国盛证券研究所


日内收益分布因子`intra_return`在 2017 年以来多空年化收益 80.6%, 多头超额收益 25.6%, 因子 IC 均值 10.3%, IC 周度胜率为 86.7%, ICIR 为 1.10。

图表 15: `intra_return` 因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	81.1%	37.4%	12.1%	90.0%	1.22
2018	75.2%	31.0%	13.5%	92.6%	1.52
2019	106.6%	32.2%	11.3%	87.7%	1.18
2020	90.1%	34.0%	10.2%	86.0%	1.01
2021	76.8%	16.9%	8.0%	85.2%	1.04
2022	67.0%	17.1%	9.0%	87.6%	1.10
20230928	35.4%	-3.4%	7.1%	74.6%	0.73
period	80.6%	25.6%	10.3%	86.7%	1.10

资料来源: wind, 国盛证券研究所

图表 16: `intra_return` 因子多头超额累计



资料来源: wind, 国盛证券研究所

3.3 其他衍生数据集合

数据集:

资金流数据集money_flow、量价因子衍生集合pv_factor:

数据特征:

money_flow: 特大单、大单、中单、小单买入/卖出金额;

pv_factor: 日收益率、开盘收益率、换手率、非流动冲击、振幅、3/5日收益率、3/5日波动率、日内波动率等11个日频特征;

数据预处理

1. 将各类型金额除以当日成交总额得到比例值;
2. 数据滚动30日窗口取数据构建数据集, 数据序列长度为30;
3. 资金流数据集中8个资金流比例特征在面板上标准化;
4. 衍生因子数据集中各个指标单独在面板标准化;


资金流因子money_flow在2017年以来多空年化收益62.0%, 多头超额收益13.7%, 因子IC均值7.2%, IC周度胜率为82.4%, ICIR为0.86。

图表 17: money_flow 因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	56.7%	18.5%	9.3%	89.1%	1.21
2018	47.0%	12.3%	7.6%	82.7%	0.89
2019	78.6%	14.7%	7.5%	76.6%	0.66
2020	75.6%	17.0%	6.8%	84.8%	0.83
2021	63.5%	11.5%	6.0%	80.7%	0.89
2022	45.1%	3.6%	5.6%	81.8%	1.01
20230928	48.8%	11.2%	7.6%	80.7%	0.88
period	62.0%	13.7%	7.2%	82.4%	0.86

资料来源: wind, 国盛证券研究所

图表 18: money_flow 因子多头超额累计



资料来源: wind, 国盛证券研究所


量价因子衍生数据集因子pv_factor在2017年以来多空年化收益85.0%, 多头超额收益29.3%, 因子IC均值9.9%, IC周度胜率为88.4%, ICIR为1.13。

图表 19: pv_factor 因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	82.2%	36.3%	12.7%	95.4%	1.57
2018	91.0%	46.3%	13.6%	94.2%	1.53
2019	100.5%	30.7%	9.8%	90.2%	1.31
2020	72.8%	16.0%	8.3%	80.3%	0.80
2021	85.9%	27.7%	7.6%	90.5%	1.21
2022	75.7%	21.5%	10.0%	87.6%	1.23
20230928	44.5%	5.6%	6.6%	78.4%	0.71
period	85.0%	29.3%	9.9%	88.4%	1.13

资料来源: wind, 国盛证券研究所

图表 20: pv_factor 因子多头超额累计



资料来源: wind, 国盛证券研究所

3.4 综合因子 nn_score

根据前文，我们根据 6 个不同数据集基于 LSTM 模型训练了 6 个因子。下图展示了这 6 个因子之间相关性的矩阵图。

整体而言，6 个因子间存在较明显的截面相关性，基于量价信息衍生出的各数据集因子相关性均在 50% 左右，而资金流因子与其他因子相关性较低，平均相关性在 30% 以下。

图表 21: 因子截面相关性矩阵图

因子	daily	weekly	minutely	intra_ret	money_flow	pv_factor
daily	—	72%	53%	55%	26%	59%
weekly	72%	—	48%	50%	25%	56%
minutely	53%	48%	—	47%	30%	46%
intra_ret	55%	50%	47%	—	26%	53%
money_flow	26%	25%	30%	26%	—	24%
pv_factor	59%	56%	46%	53%	24%	—

资料来源: wind, 国盛证券研究所


通常会基于 xgboost、lightgbm 等树模型进一步拟合因子之间的非线性信息，得到综合打分。但考虑到我们目前因子数据较少，我们直接将 6 个因子等权线性相加，得到综合深度学习因子 nn_score。

图表 22: 综合因子分年绩效

年份	多空收益	多头超额	IC均值	IC胜率	ICIR
2017	91.3%	40.7%	15.1%	94.1%	1.46
2018	106.1%	58.0%	17.3%	98.0%	1.97
2019	114.1%	31.0%	13.2%	86.9%	1.18
2020	104.2%	36.1%	11.4%	86.8%	1.05
2021	94.2%	24.3%	9.4%	91.8%	1.16
2022	88.9%	32.1%	11.3%	88.9%	1.25
20230928	60.1%	16.1%	10.3%	82.9%	0.91
period	100.8%	38.2%	12.7%	90.2%	1.23

资料来源: wind, 国盛证券研究所

图表 23: 综合因子多头超额累计



资料来源: wind, 国盛证券研究所

综合因子 nn_score 绩效相较于单一指标均呈现出一定程度的提升，因子稳定性改善。在 2017 年以来多空年化收益 100.8%，多头超额收益 38.2%，因子 IC 均值 12.7%，IC 周度胜率为 90.2%，ICIR 为 1.23。

值得注意的是，从模型分年绩效角度我们发现在 2020 年以后模型整体绩效出现比较明显衰减，并且呈现出逐年衰减的趋势。这类端到端的模型值得警惕的风险点在于模型容易产生较高的同质性。


相似的数据输入、相似的模型结构往往容易产生同质化的结果，同时由于底层 alpha 来源的相似性，实际模型收益的时序相关性可能要远高于模型打分的截面相关性。因此，设法做出差异化的结果可能是此类模型需要重点探究的方向。

图表 24: 不同预测区间下综合因子绩效

年份	2天	5天	10天	15天	20天	25天	30天
2017	11.2%	14.5%	16.1%	16.8%	17.5%	17.3%	17.0%
2018	13.6%	16.6%	18.3%	18.8%	18.5%	18.1%	17.5%
2019	11.0%	12.9%	14.3%	14.7%	14.9%	14.5%	14.1%
2020	9.2%	11.6%	12.8%	13.9%	14.3%	14.8%	15.3%
2021	7.5%	9.8%	11.1%	11.3%	11.6%	11.8%	12.0%
2022	8.7%	11.1%	12.8%	14.3%	14.8%	15.3%	15.9%
2023	8.8%	10.3%	12.5%	14.0%	15.0%	16.0%	17.2%
均值	10.0%	12.5%	14.1%	14.9%	15.2%	15.4%	15.5%

资料来源: wind, 国盛证券研究所

图表 25: 综合因子预测能力衰减



资料来源: wind, 国盛证券研究所

以 T+1 日均价为撮合价格, 分别以未来 2 天、5 天、10 天、15 天、20 天、25 天、30 天收益率为预测窗口, 因子 ic 整体随着预测窗口宽度增加而上升: 周频 ic 均值 12.5%, 双周频 ic 为 14.1%, 月频 ic 均值为 15.2%, 30 日频 ic 均值为 15.5%。


固定 5 天为预测窗口, 分别计算 T 日因子在 T+1 至 T+20 日买入的绩效, 因子选股能力随着滞后期增加而衰减, 滞后期在 10 天附近因子 ic 衰减一半, 在滞后 20 日后衰减至约 25% 水平。深度学习因子 alpha 的衰减速度并不快, 也正因此随着预测窗口增加 ic 反而出现进一步提升。

图表 26: 不同指数成分股中因子 ic

年份	沪深300	中证800	中证500	中证1000	国证2000
2017	13.0%	13.1%	13.1%	15.2%	15.0%
2018	12.4%	12.9%	12.5%	16.4%	17.7%
2019	6.0%	7.6%	8.3%	13.0%	13.9%
2020	6.7%	7.9%	8.3%	10.5%	12.3%
2021	5.8%	6.1%	6.8%	8.2%	10.5%
2022	6.0%	7.7%	8.5%	9.7%	11.5%
2023	2.9%	4.5%	5.3%	8.0%	9.6%
period	7.7%	8.7%	9.1%	11.7%	13.1%

资料来源: wind, 国盛证券研究所

图表 27: 综合因子与常用指标相关性



资料来源: wind, 国盛证券研究所

统计因子在沪深 300、中证 800、中证 500、中证 1000 和国证 2000 指数成分股中的 ic, 因子选股能力随着股票市值的减少而增加, 这与量价信息更适用于中小市值股票相一致。此外, 这类模型绩效 2019 年以后在中大市值股票域中的衰减速度显著更快, 这可能与量化基金规模的迅速增长存在一定联系。

计算综合因子与我们常用的低频指标的截面相关性, 我们发现深度学习因子与基本面信息之间几乎不存在相关性, 但是其与我们常用的反转、换手、波动等量价因子之间存在较明显的相关性。

本质上, 我们通过模型在量价信息中构建了逻辑无法解释的特征, 但这些特征的 alpha 源与量价风格还是存在明显关联, 因此在实际构建组合过程中, 常用风险模型所无法刻画短期量价类风险的控制可能是值得注意的点。

四、基于深度学习模型的指数增强策略


基于综合因子 nm_score ，我们分别构建中证 500/1000 指数增强组合，组合周度调仓，以最大化预期收益为目标，约束单次换手不超过 20%，次日均价撮合，双边千 3 计费。

4.1 中证 500 指数增强

具体的，对于中证 500 指数，风险维度我们约束：

- 个股维度：个股权重偏离不超过 0.8%；
- 行业偏离：中信一级行业权重偏离不超过 2%；
- 风格偏离：SIZE、BTOP、GROWTH 不超过 0.3 倍标准差；
- 成分股权重：指数成分股权重下限不低于 80%；

图表 28：中证 500 指数增强组合净值



资料来源：wind，国盛证券研究所

中证 500 指数增强组合 2017 年以来，组合年化收益 15.4%，超额中证 500 指数 17.1%，跟踪误差 5.7%，信息比率 2.84，月度胜率为 81.3%，年单边换手约 10 倍。

图表 29：中证 500 指数增强组合分年绩效

年份	年化超额	组合收益	基准收益	信息比率	最大回撤	超额回撤	跟踪误差	日度胜率	月度胜率
2017	23.5%	21.6%	-1.9%	4.50	-11.6%	-2.4%	4.8%	60.4%	100.0%
2018	21.8%	-11.5%	-33.3%	4.86	-29.3%	-2.1%	6.0%	63.4%	91.7%
2019	11.7%	38.1%	26.4%	1.96	-16.5%	-4.4%	4.4%	53.7%	66.7%
2020	14.1%	34.9%	20.9%	1.82	-13.4%	-4.4%	5.9%	56.4%	75.0%
2021	8.9%	24.5%	15.6%	1.27	-10.8%	-3.1%	5.9%	54.3%	83.3%
2022	14.5%	-5.8%	-20.3%	2.56	-30.0%	-4.8%	6.8%	57.9%	75.0%
20230928	10.4%	7.5%	-3.0%	2.50	-6.9%	-2.4%	4.1%	57.1%	77.8%
period	17.1%	15.4%	-1.7%	2.84	-32.6%	-6.4%	5.7%	57.6%	81.3%


资料来源：wind，国盛证券研究所

4.2 中证1000指数增强

同样的，对于中证1000指数，风险维度我们约束：

- 个股维度：个股权重偏离不超过0.5%；
- 行业偏离：中信一级行业权重偏离不超过2%；
- 风格偏离：SIZE、BTOP、GROWTH不超过0.2倍标准差；
- 成分股权重：指数成分股权重下限不低于80%；

图表 30：中证1000指数增强组合净值



资料来源：wind，国盛证券研究所

中证1000指数增强组合2017年以来，组合年化收益19.4%，超额中证1000指数24.6%，跟踪误差5.7%，信息比率4.04，月度胜率为86.3%，年单边换手约10倍。

图表 31：中证1000指数增强组合分年绩效

年份	年化超额	组合收益	基准收益	信息比率	最大回撤	超额回撤	跟踪误差	日度胜率	月度胜率
2017	25.1%	6.6%	-18.5%	5.64	-17.5%	-2.5%	4.8%	68.3%	100.0%
2018	34.5%	-2.4%	-36.9%	8.07	-29.4%	-1.4%	5.5%	68.3%	100.0%
2019	26.2%	51.8%	25.7%	4.06	-15.3%	-2.9%	4.6%	63.1%	91.7%
2020	28.3%	47.7%	19.4%	3.37	-13.0%	-3.5%	6.2%	60.9%	83.3%
2021	12.7%	33.2%	20.5%	1.64	-8.7%	-2.5%	6.0%	51.0%	83.3%
2022	16.2%	-5.4%	-21.6%	2.97	-32.4%	-2.2%	6.6%	54.1%	66.7%
20230928	10.7%	7.5%	-3.2%	2.35	-11.0%	-2.8%	4.4%	60.4%	77.8%
period	24.6%	19.4%	-5.2%	4.04	-32.4%	-4.7%	5.7%	60.9%	86.3%

资料来源：wind，国盛证券研究所

五、总结

基本面因子是低频多因子模型的重要 α 来源，然而我们发现 2021 年以来业绩类因子出现普遍性的大面积回撤。对此，我们曾经提出过三个维度的应对方案：深入基本面、拥抱 β 以及量价+AI。

前两者基于逻辑驱动，依托于投资人对于财务、宏观风格的深入理解，我们曾做过深入覆盖。而量价+AI 基于数据驱动，从模型层面捕捉市场短期的定价不充分，我们在本篇报告中展开初步探索。

金融数据具有显著的时序关联性，而深度学习中 RNN 类模型对于时序数据的建模表现最为亮眼。我们认为模型绩效的提升可以从三个维度入手：

1. 通过调整超参数选取、label 构建、数据预处理方式等精进单一模型；
2. 对同一数据集根据不同模型训练，堆叠多模型的输出；
3. 对同一模型构建差异化数据集输入，堆叠多数据集的输出；

基于 RNN 类模型中的 LSTM，我们以第三个维度为切入点，希望通过构建差异化的数据集作为模型输入，捕捉具有增量性的信息。

通过构建 6 个不同的数据集，我们训练了 6 个深度学习指标，综合 6 个指标后的深度学习因子绩效良好。2017 年以来多空年化收益 100.8%，多头超额收益 38.2%，因子 IC 均值 12.7%，ICIR 达到 1.23。

基于深度学习因子我们构建周度调仓的中证 500/1000 指数增强组合：

1. 中证 500 指数增强组合 2017 年以来，组合年化收益 15.4%，超额中证 500 指数 17.1%，跟踪误差 5.7%，信息比率 2.84。
2. 中证 1000 指数增强组合 2017 年以来，组合年化收益 19.4%，超额中证 1000 指数 24.6%，跟踪误差 5.7%，信息比率 4.04。

风险提示

结论基于历史数据以及模型推算，存在失效风险。

免责声明

国盛证券有限责任公司（以下简称“本公司”）具有中国证监会许可的证券投资咨询业务资格。本报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告的信息均来源于本公司认为可信的公开资料，但本公司及其研究人员对该等信息的准确性及完整性不作任何保证。本报告中的资料、意见及预测仅反映本公司于发布本报告当日的判断，可能会随时调整。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息及资料保持在最新状态，对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司力求报告内容客观、公正，但本报告所载的资料、工具、意见、信息及推测只提供给客户作参考之用，不构成任何投资、法律、会计或税务的最终操作建议，本公司不就报告中的内容对最终操作建议做出任何担保。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。

投资者应注意，在法律许可的情况下，本公司及其本公司的关联机构可能会持有本报告中涉及的公司所发行的证券并进行交易，也可能为这些公司正在提供或争取提供投资银行、财务顾问和金融产品等各种金融服务。

本报告版权归“国盛证券有限责任公司”所有。未经事先本公司书面授权，任何机构或个人不得对本报告进行任何形式的发布、复制。任何机构或个人如引用、刊发本报告，需注明出处为“国盛证券研究所”，且不得对本报告进行有悖原意的删节或修改。

分析师声明

本报告署名分析师在此声明：我们具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，本报告所表述的任何观点均精准地反映了我们对标的证券和发行人的个人看法，结论不受任何第三方的授意或影响。我们所得报酬的任何部分无论是在过去、现在及将来均不会与本报告中的具体投资建议或观点有直接或间接联系。

投资评级说明

投资建议的评级标准		评级	说明
评级标准为报告发布日后的 6 个月内公司股价（或行业指数）相对同期基准指数的相对市场表现。其中 A 股市场以沪深 300 指数为基准；新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为基准；香港市场以摩根士丹利中国指数为基准，美股市场以标普 500 指数或纳斯达克综合指数为基准。	股票评级	买入	相对同期基准指数涨幅在 15%以上
		增持	相对同期基准指数涨幅在 5%~15%之间
		持有	相对同期基准指数涨幅在 -5%~+5%之间
		减持	相对同期基准指数跌幅在 5%以上
	行业评级	增持	相对同期基准指数涨幅在 10%以上
		中性	相对同期基准指数涨幅在 -10%~+10%之间
		减持	相对同期基准指数跌幅在 10%以上

国盛证券研究所

北京

地址：北京市东城区永定门西滨河路 8 号院 7 楼中海地产广场东塔 7 层

邮编：100077

邮箱：gsresearch@gszq.com

南昌

地址：南昌市红谷滩新区凤凰中大道 1115 号北京银行大厦

邮编：330038

传真：0791-86281485

邮箱：gsresearch@gszq.com

上海

地址：上海市浦明路 868 号保利 One56 1 号楼 10 层

邮编：200120

电话：021-38124100

邮箱：gsresearch@gszq.com

深圳

地址：深圳市福田区福华三路 100 号鼎和大厦 24 楼

邮编：518033

邮箱：gsresearch@gszq.com