

核心观点

分析师 缪铃凯

SAC 证书编号: S0160525060003

miaolk@ctsec.com

相关报告

1. 《指增组合本周全面跑赢基准》
2025-07-27
2. 《中证 1000 增强今年超额收益 9.9%》
2025-07-19
3. 《沪深 300 增强今年超额收益 9.8%》
2025-07-13

❖ **特征提取:** 基于“时序+截面”的基础架构，我们设计了五类差异化类网络结构，这些网络对同一输入能得到低相关因子输出。基于日度行情、分钟行情以及手工特征三类数据，我们训练了 10 个模型，模型间平均相关性仅 55%。

❖ **Alpha 信号:** 基于线性等权、树模型与专家网络三类加权方式，我们将数百个神经网络特征集成为 alpha 信号。综合因子自 2019 年以来 5 日 IC 均值为 13.3%，10 日 IC 均值为 15.0%，多头组合超额收益为 49.0%。

❖ **风险模型:** 相较于传统 barra 等风险模型基于投资逻辑构建风险特征，我们用神经网络通过端到端学习模式直接从原始量价数据中识别高维非线性风险模式。风险因子长期不暴露 alpha，同时表现出对截面收益的高解释能力。

❖ **指增策略:** 基于深度学习 alpha 信号与风险特征，我们构建系列指增策略：

1. 自 2019 年以来，沪深 300 指数增强组合年化收益为 18.2%，相比于沪深 300 指数的超额收益为 14.2%，跟踪误差为 4.5%；
2. 中证 500 指数增强组合年化收益为 22.4%，相比于中证 500 指数的超额收益为 17.2%，跟踪误差为 4.8%；
3. 中证 1000 指数增强组合年化收益为 29.8%，相比于中证 1000 指数的超额收益为 24.5%，跟踪误差为 5.4%。

❖ **风险提示:** 因子失效风险、模型失效风险、市场风格变动风险



内容目录

1	深度学习选股策略	4
2	数据与网络	5
2.1	数据输入	5
2.2	网络结构	6
2.3	模型训练	7
2.4	日度行情	8
2.5	分钟行情	13
2.6	统计指标	15
3	alpha 模型	16
3.1	简单等权	16
3.2	树模型加权	17
3.3	网络加权	19
3.4	综合信号	20
4	风险模型	21
5	指数增强组合	22
5.1	沪深 300 指数增强	23
5.2	中证 500 指数增强	24
5.3	中证 1000 指数增强	25
6	风险提示	26

图表目录

图 1:	日行情因子相关性	13
图 2:	模型相关性	16
图 3:	树模型加权因子多头	18
图 4:	风险因子 IC 序列	21
图 5:	沪深 300 增强组合净值	23
图 6:	中证 500 增强组合净值	24



图 7: 中证 1000 增强组合净值.....	25
表 1: 日度行情模型 1 (30 日)	8
表 2: 日度行情模型 1 (150 日)	8
表 3: 日度行情模型 2	9
表 4: 日度行情模型 3	10
表 5: 日度行情模型 4	11
表 6: 日度行情模型 5	12
表 7: 2 小时行情模型	14
表 8: 半小时行情模型	14
表 9: 日/分钟行情因子相关性	14
表 10: 简单统计特征	15
表 11: 选股因子特征	15
表 12: 等权因子绩效	16
表 13: 集成因子绩效 (1 年训练集)	17
表 14: 集成因子绩效 (3 年训练集)	17
表 15: 树模型加权因子绩效	18
表 16: 网络加权因子绩效	19
表 17: 综合因子绩效	20
表 18: 综合因子分域绩效	20
表 19: 风险因子绩效	21
表 20: 沪深 300 增强组合绩效	23
表 21: 中证 500 增强组合绩效	24
表 22: 中证 1000 增强组合绩效	25

1 深度学习选股策略

在当今快速发展的金融市场中，如何有效利用深度学习技术进行股票预测和投资组合优化已成为众多投资者关注的焦点。传统的多因子模型通常通过**手工构建**因子来预测股票截面收益，并进一步通过组合优化得到股票持仓。

然而多因子模型依赖线性回归与人工因子挖掘，在处理高频非结构化数据时存在维度灾难与特征表达不足的问题。深度学习通过端到端学习与自动特征提取，为解决上述痛点提供了新范式。

与传统方法不同，我们将获取超额收益的方式从理解市场、理解基本面切换到了数据建模层面，将研究重心从“逻辑驱动”转向“数据驱动”，通过深度学习挖掘高频数据中的非线性模式，弥补传统框架在短期定价效率上的不足。

在“原始数据→自动特征提取→因子合成”的端到端学习框架下，我们将**深度学习指数增强体系**的构建目标定位于以下几个方面：

多模态：

多样化数据源是模型性能的基础保障，融合日度行情、分钟行情、手工特征、基本面财务指标等多样化信息，提升 alpha 信号的边际效能。

多模型：

基于“时序+截面”的基础架构，通过设计差异化类网络结构，在单一数据集中多次训练以获取增量信息；对于网络提取的因子特征，采用多类别因子集成模型，提升最终 alpha 信号的稳健性。

全流程：

风险控制是构建稳健投资组合不可或缺的一环，以往风险模型通常是基于金融逻辑构建风险特征，而使用神经网络则可以通过端到端学习模式直接从原始量价数据中识别高维非线性风险模式，让深度学习同时赋能 alpha 模型和风险模型。

低换手：

以往“AI+量价”类模型通常追求高换手，赚取市场中短期交易性机会，使用更长预测窗口、更长的回看周期构建 alpha 信号，训练流程中更多地融合基本面信息，减缓了 alpha 信号的衰减，使得模型更适配低换手的交易模式。

最终，我们基于深度学习构建了沪深 300、中证 500 及中证 1000 指数增强策略：同等换手水平前提下，策略相对传统多因子模型能获得更高超额收益，同时保持更低收益波动和回撤水平。

2 数据与网络

2.1 数据输入

按照数据频率，我们使用日度行情、分钟行情和手工特征一共 3 类数据集合，利用神经网络在各类数据集中独立提取 alpha 特征。

1) 日度行情

数据特征：

开盘价、最高价、最低价、收盘价、均价、成交量、成交额

数据预处理：

a) 价格数据通过对数变换在时序维度转换成对数收益率：

$$\text{价格}_{t-i} = \log(\text{价格}_{t-i} / \text{收盘价}_t)$$

b) 成交量（成交额）数据通过序列均值进行标准化：

$$\text{成交量}_{t-i} = \text{成交量}_{t-i} / \text{average}(\text{成交量})$$

$$\text{成交额}_{t-i} = \text{成交额}_{t-i} / \text{average}(\text{成交额})$$

2) 分钟行情

数据特征：

开盘价、最高价、最低价、收盘价、均价、成交量、成交额

数据预处理：

与日行情一致，通过价格对数转换和成交量（成交额）均值标准化实现特征统一。

3) 统计指标

数据特征：

a) 基础统计特征：资金流、日内收益分布；

b) 选股因子特征：基本面因子、量价因子；

数据预处理：

基础统计特征直接使用原始数据，选股因子特征则采用截面 z-score 标准化。

2.2 网络结构

长短期记忆网络(LSTM)模型通过时间维度上的迭代处理捕捉序列长期依赖关系，但其计算过程仅限于单一样本内部，无法建模样本间的交互特征。为弥补这一局限性，我们采用时序网络和截面网络组合的架构，实现多维度捕捉市场特征。

时序网络

我们采用 LSTM 结合自注意力(self-attention)机制的结构，以有效捕捉股票时间序列中的长期依赖关系。

LSTM 通过门控结构(遗忘门、输入门、输出门)选择性保留历史信息，适用于处理非平稳的股票价格序列，能够精准捕捉到关键的时序动态。而自注意力机制进一步强化序列内部关键时间点的权重分配，可有效识别重大事件日或趋势转折点等具有显著影响力的特征。

截面网络

在实际的投资决策中，除了单只股票的时间序列信息外，股票间的截面关联同样蕴含着重要信息。为了捕捉股票间的相互关系，我们引入了图注意力网络 GAT (Graph Attention Network)。该网络通过注意力机制来描述股票间的复杂截面关系，提供市场动态的全局分析视角。

基础网络结构

最终，融合时序和截面网络之后，基础网络结构 baseline 为：

$$LSTM \rightarrow self\ attention \rightarrow GAT \rightarrow MLP$$

- 1) LSTM 层对每个样本的时序数据进行建模，通过门控机制保留历史信息，生成包含长期依赖特征的隐藏状态序列；
- 2) 在 LSTM 输出端接入自注意力机制，进一步捕捉序列内部关键时间点的权重分配，强化对趋势转折点与重大事件日的特征响应；
- 3) 将自注意力层的输出向量作为图注意力网络 GAT 的输入节点特征，通过注意力系数计算股票间的非线性关联权重，建模截面联动关系；
- 4) MLP 之后得到网络模型输出，其为 $N \times F$ 为矩阵（股票*因子数量）。

我们将 $LSTM \rightarrow self\ attention$ 视作一个整体，简记为 RNN ；将 $GAT \rightarrow MLP$ 视作一个整体，简记为 GAT ；二者组合得到的基础复合模型记为 $RNN - GAT$ 。

为了充分提取原始数据中的信息，我们在模型 $RNN - GAT$ 的基础上构建了 5 类差异化的网络结构，分析结果表明即使输入相同的数据，不同网络模型可以在该数据上提取差异化的 α 信号。

2.3 模型训练

因子输出

使用上述 3 类数据集训练 10 个模型，模型输出为因子集合，包含：

- 1) 日度行情数据：5 个因子集合；
- 2) 分钟行情数据：3 个因子集合；
- 3) 统计指标数据：2 个因子集合。

其中，每个因子集合包含 N 个信号，模型绩效基于 N 个信号均值评估。

滚动训练

采用滚动时间窗口训练策略，每年滚动训练 1 次，以前七年的数据作为训练集，最近 2 年的数据作为验证集。

批量训练与样本构建

- 1) 按日期拆分数据，每个 batch 样本为 T 日全市场股票数据；
- 2) 每个 epoch 在训练集中随机抽取 batch 进行训练。

损失函数设计

采用 MSE 作为基础损失函数，并加入相关性正则项以抑制特征间的冗余关联。

标签定义

标签定义：预测目标标签 $label_t$ 定义为股票未来 N 日的 Alpha 收益，计算方式如下：

$$label_t = neutralize(price_{t+11}/price_{t+1} - 1)$$

其中， $neutralize$ 表示中性化处理。对于训练数据的标签，我们使用同类型股票 $SimStock_i$ 的平均收益作为基准，刻画股票 i 的预期 Alpha 收益。股票相似性基于收益率相关性刻画：

$$SimStock_i = \{j: corr(ret_i, ret_j) \geq threshold\}$$

其中 ret_i 为股票 i 日收益序列。

早停机制

采取早停机制防止训练过拟合，早停次数为 15 轮。

2.4 日度行情

出于算力与信息平衡考虑，传统建模通常使用 30 日量价信息，但自 2023 年以来该时间窗口的 Alpha 出现明显的衰减。

我们分别采用时序长度为 30 日和 150 日的行情信息独立提取因子特征，对比结果发现，自 2019 至 2022 年间，两者绩效接近，从 2023 年开始，30 日行情的多头超额收益出现明显衰减。

1) 模型 1: RNN-GAT

表1：日度行情模型 1（30 日）

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	114.2%	36.9%	4.97	13.5%	14.7%
2020	106.8%	38.8%	3.97	11.6%	12.3%
2021	99.3%	29.1%	2.49	10.3%	11.1%
2022	88.1%	32.2%	4.53	11.9%	13.0%
2023	54.0%	5.1%	0.72	8.7%	9.8%
2024	81.3%	12.4%	0.81	10.8%	12.0%
202506	51.7%	12.4%	2.02	14.6%	16.4%
period	94.1%	26.6%	2.22	11.3%	12.4%

数据来源：Wind，财通证券研究所

基于 RNN-GAT 模型提取的 30 日行情因子，自 2019 年以来 5 日 IC 均值为 11.3%，10 日 IC 均值为 12.4%，多头超额收益为 26.6%。因子多头超额收益在 2023 年之后出现显著下降。

表2：日度行情模型 1（150 日）

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	106.9%	33.2%	4.32	12.8%	14.3%
2020	100.5%	42.0%	5.16	9.3%	10.1%
2021	87.7%	29.1%	2.82	8.1%	8.3%
2022	90.3%	37.0%	4.81	10.7%	12.0%
2023	70.3%	20.2%	3.33	10.7%	12.7%
2024	90.0%	31.2%	1.68	8.9%	9.4%
202506	54.4%	19.7%	5.28	14.5%	16.4%
period	96.6%	35.0%	3.07	10.4%	11.5%

数据来源：Wind，财通证券研究所

基于 RNN-GAT 模型提取的 150 日行情因子，自 2019 年以来 5 日 IC 均值为 10.4%，10 日 IC 均值为 11.5%，多头超额收益为 35.0%，2023 年以后因子多头组合超额收益未出现明显衰减。由于短序列信息在近几年 alpha 衰减明显，我们在本文中均使用长序列行情数据。

2) 模型 2: CNN-RNN-GAT

RNN-GAT 模型在网络结构维度可以在时序结构和截面结构进行调整，我们尝试对网络时序结构进行改变。

长序列数据进入 RNN 模型可能存在信息遗忘等问题，我们尝试通过卷积神经网络（CNN）在时序维度聚合长序列。

具体来说，在数据进入神经网络之前，数据先过卷积层。令每 5 根日线共享 CNN 网络，将数据处理成周线特征，最终将 150 日数据整合成序列长度为 30 的周线信息，进入时序网络。

我们采用 ResNet 结构从原始数据中提取特征：

$$input_{B*150*F} \xrightarrow{ResNet} input'_{B*30*F}$$

其中残差块内，输入序列先经“1 维卷积（捕捉局部时序模式）→ ReLU（引入非线性）→ 1 维卷积（强化特征交互）”构成的残差变换，同时以轻量 1 维卷积对输入做维度对齐，最终通过残差连接融合原始输入与变换特征，数学形式为：

$$Output = Conv_{\{skip\}(x)} + Conv_2 \left(ReLU(Conv_1(x)) \right)$$

该结构既利用卷积挖掘时序关联，又通过残差机制让模型优先学习“输入-输出”的残差，适配金融数据噪声干扰下的特征学习需求，有效提升深度网络对长周期趋势的建模能力。最后， $input'_{B*30*F}$ 经过 RNN-GAT 输出因子特征。

表3：日度行情模型 2

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	107.3%	38.3%	5.83	11.5%	12.7%
2020	107.0%	46.0%	5.44	10.6%	11.8%
2021	100.8%	40.4%	3.05	8.4%	8.6%
2022	80.3%	28.6%	3.85	11.2%	12.8%
2023	72.6%	22.8%	3.65	10.0%	11.3%
2024	96.2%	27.7%	1.48	12.2%	12.6%
202506	45.2%	12.6%	3.89	12.2%	14.7%
period	97.5%	35.0%	2.89	10.7%	11.8%

数据来源：Wind，财通证券研究所

基于 CNN-RNN-GAT 模型得到的因子，自 2019 年以来 5 日 IC 均值为 10.7%，10 日 IC 均值为 11.8%，多头超额收益为 35.0%，因子绩效与模型 1 接近。

模型 2 与模型 1 使用相同数据输入，仅仅改变时序网络结构，但网络提取出的因子特征相关性较低，因子值截面相关性仅 62%。

3) 模型 3: RNN-GAT2

对于模型 3，我们尝试对 RNN-GAT 模型的截面网络进行调整，图模型 GAT 的核心依托于样本间的预定义邻接关系，因此我们通过调整邻接矩阵获取信息增量。

对于图网络模型而言，邻接矩阵 A 的定义至为重要：

$$GAT_{output} = GAT(input, A).$$

在 RNN-GAT 中，我们以行业编码来构建邻接矩阵，股票间的连通性取决于它们是否属于同一行业，矩阵元素 $A_{ij} = 1$ 当且仅当 $industry_i = industry_j$ ，否则 $A_{ij} = 0$ ：

$$\begin{pmatrix} 1 & 1 & \dots & 0 & 0 \\ 1 & 1 & & 0 & 0 \\ \vdots & & \ddots & \vdots & \\ 0 & 0 & \dots & 1 & 1 \\ 0 & 0 & & 1 & 1 \end{pmatrix}$$

而在 RNN-GAT2 中我们使用隐式相关性关联来描述股票之间的关系。具体的邻接矩阵构建方法如下：

- 1) 初始化股票间原始邻接矩阵 $A_{style} = ones(N, N)$ ，N 为股票数；
- 2) 根据股票历史收益序列，计算股票间的协方差矩阵： $corr = correlation(ret)$ ；
- 3) 对于任意股票 $i = 1, \dots, N$ ，选取与其日收益率相关性最高的 k 只股票，作为邻接节点，它们的下标为： $idx = argtopk(corr[i, :])$ ；
- 4) 股票 i 与其余股票均不连通，即： $A_{style}[i, -idx] = 0$ 。

表4：日度行情模型 3

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	110.6%	39.4%	6.79	12.1%	13.7%
2020	93.0%	30.4%	3.75	10.8%	12.1%
2021	100.9%	33.4%	2.78	9.5%	10.7%
2022	97.8%	42.2%	5.80	11.6%	12.7%
2023	67.9%	17.6%	2.99	8.9%	10.4%
2024	105.3%	39.1%	2.16	10.6%	11.3%
202506	50.1%	14.4%	5.18	13.1%	15.0%
period	100.4%	35.6%	3.21	10.8%	12.0%

数据来源：Wind，财通证券研究所

基于 RNN-GAT2 模型得到的因子，自 2019 年以来 5 日 IC 均值为 10.8%，10 日 IC 均值为 12.0%，多头超额收益为 35.6%，因子绩效与模型 1 接近。

模型 3 与模型 1 使用相同数据输入，仅改变截面邻接关系，但网络提取出的因子特征相关性较低，因子值截面相关性仅 62%。

4) 模型 4: RNN-GAT2-FUNDA

模型 2 和模型 3 在模型 1 基础上分别改变时序和截面的结构，在模型 4 中，我们尝试引入基本面信息，让量价和基本面混合训练，期望借助信息共振获取增量。

首先，短期内基本面财务因子在时序维度的变化并不明显，但基本面因子相比于量价因子在截面上样本之间的关联信息应该更强。因此，基本面信息只经过截面网络而不经时序网络。

具体来说，将选取的核心基本面指标经标准化处理后与 LSTM 隐藏层输出进行特征拼接，形成融合市场时序特征与财务基本面信息的复合表征，并将拼接后的混合特征输入图注意力网络 GAT。

RNN-GAT2-Funda 网络流程如下：

- 1) LSTM 网络输出隐藏层: $input \xrightarrow{RNN} hidden$;
- 2) 合并基本面信息: $hidden' = concat(hidden, funda)$;
- 3) 隐藏层经过图网络 1: $hidden' \xrightarrow{GAT_1} output_1$;
- 4) 隐藏层经过图网络 2: $hidden' \xrightarrow{GAT_2} output_2$;
- 5) 合并图网络输出: $output' = concat(output_1, output_2)$;
- 6) MLP 得到最终输出: $output' \xrightarrow{MLP} output$;

其中，时序网络提取的截面量价信号 $hidden$ 和截面基本面财务信号 $funda$ 在时序网络之后、截面网络之前拼接成 $hidden'$ 。

表5：日度行情模型 4

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	102.8%	30.7%	5.05	11.7%	13.2%
2020	123.2%	59.4%	7.16	11.4%	12.4%
2021	105.9%	41.2%	2.94	9.9%	11.1%
2022	99.2%	47.1%	7.20	12.0%	14.2%
2023	61.3%	16.6%	2.73	9.0%	10.9%
2024	104.1%	38.7%	2.22	10.9%	12.2%
202506	40.7%	8.1%	2.00	11.7%	13.8%
period	101.8%	39.1%	3.37	10.9%	12.4%

数据来源：Wind，财通证券研究所

基于 RNN-GAT2-Funda 模型得到的因子，自 2019 年以来 5 日 IC 均值为 10.9%，10 日 IC 均值为 12.4%，多头超额收益为 39.1%。在模型 4 中加入基本面信息之后多头提升明显，同时与模型 1 相关性进一步下降，因子值截面相关性均值仅 55%。

5) 模型 5: CNN-RNN-GAT2-FUNDA

模型 2 在模型 1 基础之上通过卷积网络改变时序结构，相似地，模型 5 在模型 4 基础上增加卷积结构，让行情数据先经过卷积层后再提取时序特征与基本面信息进行组合。

模型 5 结构与模型 4 相似，网络流程如下：

- 1) CNN 网络: $input \xrightarrow{CNN} input'$;
- 2) LSTM 网络输出隐藏层: $input' \xrightarrow{RNN} hidden$;
- 3) 合并基本面信息: $hidden' = concat(hidden, funda)$;
- 4) 隐藏层经过图网络 1: $hidden' \xrightarrow{GAT_1} output_1$;
- 5) 隐藏层经过图网络 2: $hidden' \xrightarrow{GAT_2} output_2$;
- 6) 合并图网络输出: $output' = concat(output_1, output_2)$;
- 7) MLP 得到最终输出: $output' \xrightarrow{MLP} output$.

其中，行情数据经过卷积网络在时间维度降维得到 $input'$ ，再通过 RNN 网络得到截面量价信号 $hidden$ ；融合截面基本面财务信号 $funda$ 之后分别经过基于行业和相似性邻接关系的 GAT 模型；两个 GAT 模型的输出融合之后经过 MLP 得到最终的因子输出。

表6：日度行情模型 5

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	99.8%	30.5%	4.81	11.8%	13.1%
2020	109.2%	47.7%	6.00	11.2%	12.6%
2021	103.6%	41.0%	3.65	9.7%	10.7%
2022	82.6%	33.2%	4.73	10.6%	11.9%
2023	64.2%	18.1%	3.16	8.9%	10.5%
2024	103.7%	39.6%	2.49	11.1%	12.1%
202506	42.7%	10.5%	3.14	12.8%	14.4%
period	96.7%	35.7%	3.49	10.7%	12.0%

数据来源：Wind，财通证券研究所

基于 CNN-RNN-GAT2-Funda 模型得到的因子，自 2019 年以来 5 日 IC 均值为 10.7%，10 日 IC 均值为 12.0%，多头超额收益为 35.7%。

模型 5 与模型 1 具有较明显独立性，因子值截面相关性进一步下降到 54%；模型 5 与模型 4 在数据和网络结构上相似性较高，两模型相关性为 70%。

基于日度行情数据，我们采用 5 类网络模型提取因子信息，下表展示了 5 个日行情模型的平均相关性。

图1：日行情因子相关性

模型	1	2	3	4	5
1	—	62%	62%	55%	54%
2	62%	—	64%	59%	62%
3	62%	64%	—	60%	59%
4	55%	59%	60%	—	70%
5	54%	62%	59%	70%	—

数据来源：Wind，财通证券研究所

5 个日行情模型因子值相关性均值为 60%，整体呈现出较低相关性，且因子绩效接近。这表明在数据输入信息足够丰富的前提下，采用多模型反复提取特征能获得显著的增量 alpha 信息。

2.5 分钟行情

相比于日行情，分钟行情拥有精细的颗粒度，基于分钟行情提取的因子信息与日行情具有较高的独立性。

首先，对于分钟行情我们秉承与日度行情一致的处理思路，尽可能使用长序列数据，让数据输入拥有足够的信息量。

我们尝试使用 2 小时和半小时 K 线两类不同颗粒度数据进行建模：

- 1) 两小时分钟线，使用 300 根，共计 150 天信息；
- 2) 半小时分钟线，使用 720 根，共计 90 天信息；

由于分钟数据在时序维度较长，我们先用卷积网络进行降维处理，以网络模型 5 CNN-RNN-GAT2-Funda 为例，我们展示模型在两类分钟行情中因子绩效。

此外，对于分钟数据的预处理，我们建议采用与日行情一致的方案，所有价格用序列起始或者终止点价格进行时序标准化；相反的，如果简单将日内价格相对日内收盘价进行时序标准化，股票价格在日与日之间的联系将会被打断。

表7：2小时行情模型

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	101.9%	32.4%	5.26	11.6%	12.9%
2020	97.5%	36.0%	4.60	10.5%	11.6%
2021	89.6%	35.5%	2.97	8.3%	8.8%
2022	84.0%	33.4%	5.31	11.1%	12.9%
2023	65.1%	18.4%	2.94	8.9%	10.4%
2024	102.4%	35.9%	2.17	10.6%	12.0%
202506	50.2%	14.7%	3.92	13.7%	15.9%
period	94.9%	33.8%	3.09	10.4%	11.7%

数据来源：Wind，财通证券研究所

基于2小时行情提取的因子，自2019年以来5日IC均值为10.4%，10日IC均值为11.7%；多头组合年后超额收益为33.8%，多头IR为3.09。因子绩效略弱于日行情，但因子与日行情平均相关性在60%附近。

表8：半小时行情模型

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	102.2%	26.5%	4.82	11.6%	12.9%
2020	93.4%	31.4%	3.52	9.2%	9.9%
2021	84.7%	28.5%	3.02	8.1%	8.9%
2022	89.4%	36.5%	4.14	10.3%	12.2%
2023	66.9%	20.9%	2.83	9.7%	11.1%
2024	109.7%	43.0%	2.24	10.8%	12.0%
202506	46.3%	11.5%	3.55	12.1%	13.8%
period	95.5%	32.7%	2.84	10.1%	11.4%

数据来源：Wind，财通证券研究所

基于半小时行情提取的因子，自2019年以来5日IC均值为10.1%，10日IC均值为11.4%；多头组合年后超额收益为32.7%，多头IR为2.84。因子绩效略弱于日行情，但因子独立性显著，其与部分日行情因子相关性降低到约45%上下。

表9：日/分钟行情因子相关性

因子	daily 1	daily 2	daily 3	daily 4	daily 5
minutely 1	57.0%	66.2%	63.2%	59.3%	62.3%
minutely 2	44.3%	46.4%	46.6%	58.6%	60.3%

数据来源：Wind，财通证券研究所

两小时行情与半小时行情因子截面相关性约为50%，两因子与5个日线因子平均相关性约为56%，分钟信息对于组合的增量alpha贡献明显。

2.6 统计指标

对于统计指标数据，我们使用两类不同的特征分别训练模型，具体设计如下：

- 1) 未经过预处理的简单统计特征，如资金流中的大小单占比等；
- 2) 手工构建的标准化选股因子，如基本面、量价因子；

由于量价指标使用长时序信息无太大意义，因此我们采用 30 天数据，并使用模型 RNN-GAT2-Funda 进行训练。

基于简单统计特征提取的因子，自 2019 年以来 5 日 IC 均值为 10.1%，10 日 IC 均值为 11.5%；多头组合超额收益为 24.4%，多头 IR 为 3.02。

表10： 简单统计特征

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	118.7%	40.7%	7.66	12.0%	13.5%
2020	92.5%	26.5%	3.43	9.4%	10.6%
2021	88.1%	19.4%	2.87	9.0%	10.2%
2022	67.3%	15.6%	3.30	9.6%	11.1%
2023	68.1%	18.8%	3.37	9.7%	11.0%
2024	80.4%	13.8%	1.24	9.4%	9.8%
202506	55.2%	17.6%	6.98	14.6%	17.2%
period	90.1%	24.4%	3.02	10.1%	11.5%

数据来源：Wind，财通证券研究所

基于选股因子特征提取的因子，自 2019 年以来 5 日 IC 均值为 10.8%，10 日 IC 均值为 12.1%；多头组合超额收益为 31.1%，多头 IR 为 2.83。

表11： 选股因子特征

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	116.7%	40.5%	7.26	12.8%	14.5%
2020	107.5%	40.9%	5.06	10.7%	11.7%
2021	91.7%	29.4%	3.40	9.3%	10.4%
2022	78.7%	24.9%	4.12	9.1%	10.3%
2023	75.0%	25.9%	3.33	10.8%	12.6%
2024	77.2%	10.2%	0.76	10.1%	10.7%
202506	61.5%	20.7%	7.94	15.7%	17.8%
period	96.6%	31.1%	2.83	10.8%	12.1%

数据来源：Wind，财通证券研究所

结果显示，两因子相关性约为 55%，因子与行情特征因子相关性约为 45%，信息增量明显。

3 alpha 模型

我们基于日行情构建 5 个模型、分钟行情 3 个模型、统计特征 2 个模型，最终生成 10 个模型，每个模型内 64 个信号，共 640 个信号。模型绩效以模型内 64 个信号均值作为综合信号统计。我们分别尝试不同集成模式构建最终 alpha 信号。

3.1 简单等权

如下图所示，基于 3 类数据得到的 10 个因子集合的平均相关性约为 55%，因子集之间的信息独立性较明显。

图2： 模型相关性

模型	1	2	3	4	5	6	7	8	9	10
1	-	62%	62%	55%	54%	57%	49%	44%	44%	38%
2	62%	-	64%	59%	62%	66%	56%	46%	44%	36%
3	62%	64%	-	60%	59%	63%	53%	47%	47%	39%
4	55%	59%	60%	-	70%	59%	67%	59%	52%	49%
5	54%	62%	59%	70%	-	62%	70%	60%	51%	50%
6	57%	66%	63%	59%	62%	-	62%	51%	47%	40%
7	49%	56%	53%	67%	70%	62%	-	63%	53%	51%
8	44%	46%	47%	59%	60%	51%	63%	-	56%	54%
9	44%	44%	47%	52%	51%	47%	53%	56%	-	55%
10	38%	36%	39%	49%	50%	40%	51%	54%	55%	-

数据来源：Wind，财通证券研究所

在模型间两两低相关性的前提下，信号等权通常就能取得极佳效果。

我们将以上各类因子简单平均得到等权因子。结果显示，等权因子 2019 年以来 5 日 IC 均值为 12.9%，10 日 IC 均值为 14.5%；多头组合年后超额收益为 42.7%，多头 IR 为 3.36。因子绩效相比于任意单一模型大幅提升。

表12： 等权因子绩效

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	118.4%	36.5%	5.67	14.5%	16.3%
2020	121.9%	49.9%	5.38	12.8%	14.2%
2021	111.2%	42.7%	3.19	11.2%	12.2%
2022	106.8%	50.5%	6.24	13.3%	15.2%
2023	76.9%	23.2%	3.16	11.6%	13.6%
2024	109.7%	38.2%	1.92	12.7%	13.7%
202506	58.0%	18.2%	5.25	16.1%	18.5%
period	112.6%	42.7%	3.36	12.9%	14.5%

数据来源：Wind，财通证券研究所

3.2 树模型加权

相比于简单线性等权处理，非线性加权往往能一定程度提升因子的多头组合绩效。我们以树模型为例，展示了信号加权的過程。

2024 年市场风格的继续切换给予我们的历史教训在于模型不应该过度追随风格。以 LightGBM 为例，每 2 个月滚动训练一次模型，我们展示分别以滚动 1 年和 3 年数据作为训练集合的分析结果。

表13： 集成因子绩效（1 年训练集）

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	128.8%	44.8%	6.90	12.8%	14.1%
2020	118.0%	45.4%	5.70	10.9%	12.1%
2021	126.1%	50.6%	4.47	9.9%	11.1%
2022	98.6%	41.3%	5.55	12.9%	15.0%
2023	80.3%	24.9%	3.93	10.9%	12.8%
2024	105.3%	34.7%	1.89	9.9%	11.2%
period	113.0%	42.0%	3.67	11.2%	12.7%

数据来源：Wind，财通证券研究所

1 年窗口得到的树模型集成信号 2019 年以来 5 日 IC 均值为 11.2%，10 日 IC 均值为 12.7%；多头组合年后超额收益为 42.0%，多头 IR 为 3.67。

表14： 集成因子绩效（3 年训练集）

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	135.2%	49.5%	7.88	14.1%	15.8%
2020	128.0%	52.2%	6.40	11.6%	12.8%
2021	129.8%	52.4%	3.99	10.7%	11.9%
2022	102.3%	43.4%	6.02	12.5%	14.5%
2023	84.7%	27.0%	4.47	10.6%	12.6%
2024	111.1%	40.7%	2.02	10.7%	12.1%
period	118.8%	46.1%	3.78	11.7%	13.2%


数据来源：Wind，财通证券研究所

而 3 年窗口得到的树模型集成信号 2019 年以来 5 日 IC 均值为 11.7%，10 日 IC 均值为 13.2%；多头组合年后超额收益为 46.1%，多头 IR 为 3.78。

对比可知，无论对于多头超额收益、5 日 IC 或 10 日 IC，3 年训练窗口得到的集成信号均优于 1 年训练窗口得到的集成信号。

我们采用 LightGBM、XGBoost、CatBoost 三类梯度提升树模型进行集成，每两个月滚动训练一次模型，使用最近 3 年数据进行训练，对于不同模型的预测值取简单平均得到树模型预测结果。

图3： 树模型加权因子多头



数据来源：Wind，财通证券研究所

树模型加权因子自 2019 年以来 5 日 IC 均值为 11.9%，10 日 IC 均值为 13.3%。多头组合超额收益为 43.1%，多头 IR 为 3.70。

树模型稳定性不如等权模型，因子 IC 相比等权模型出现下降，但是多头组合超额收益和多头组合 IR 均出现明显提升。

表15： 树模型加权因子绩效

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	135.8%	51.6%	8.12	14.4%	16.1%
2020	120.5%	47.2%	6.18	11.3%	12.5%
2021	122.4%	49.4%	4.12	10.5%	11.5%
2022	91.4%	33.5%	5.22	11.7%	13.5%
2023	85.3%	25.9%	3.59	11.2%	13.2%
2024	107.4%	38.3%	1.99	10.8%	11.4%
202506	61.5%	19.3%	7.39	14.8%	16.7%
period	115.0%	43.1%	3.70	11.9%	13.3%

数据来源：Wind，财通证券研究所

3.3 网络加权

相比于等权或是使用传统机器学习算法集成信号，神经网络加权拥有更高的灵活度。我们设计了一个多专家集成架构来加权信号集合。

我们采用基于时序卷积网络（TCN）的多专家集成架构，一共设置 4 个 Expert 专家网络。TCN 相比等权或者树模型，其单一样本并非仅是信号的截面信息，而是信号在时序变动的面板信息。

由于信号数量较多，我们将样本为股票最近 5 个交易日的因子值，TCN 网络使用 2 年数据为训练集，1 年为验证集。

此外，我们希望加权模型能自适应市场风格变化，我们通过一个简单路由结构为每个模型中的每个样本动态复权：

$$q = \text{transform}(\text{style})$$

$$k = \text{transform}(\text{env})$$

$$\text{gate_weights} = F.\text{softmax}(q * k, \text{dim} = -1)$$

其中 *style* 为样本的风格暴露信息，*env* 为市场环境变量信息，*gate_weights* 为样本权重矩阵，其维度为 *batch * num_expert*。

最后综合各个专家打分得到最终集成信号：

$$\text{output} = \sum_{\{\text{expert id}\}} \text{expert}(\text{input}) * \text{gate_weights}[:, \text{expert id}] .$$

神经网络加权因子自 2019 年以来 5 日 IC 均值为 12.3%，10 日 IC 均值为 13.7%。多头组合超额收益为 44.9%，多头 IR 为 3.61。因子多头超额收益高于等权模型和树模型，IC 均值介于二者之间。

表16： 网络加权因子绩效

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	138.1%	55.4%	7.96	14.2%	16.0%
2020	120.7%	49.0%	5.91	12.2%	13.4%
2021	118.3%	49.0%	3.60	11.1%	12.1%
2022	95.7%	38.8%	5.88	11.7%	13.5%
2023	79.8%	23.3%	3.45	11.0%	12.9%
2024	108.3%	38.7%	1.94	11.5%	11.9%
202506	62.7%	21.5%	7.62	16.9%	19.4%
period	115.3%	44.9%	3.61	12.3%	13.7%

数据来源：Wind，财通证券研究所

3.4 综合信号

不局限于单一集成模式，我们将等权模型、树模型和网络模型三类信号取简单平均。同时考虑到网络训练的随机性，从特征提取到特征集成，我们基于两个不同的随机种子分别训练，得到的结果取简单平均。

综合因子自 2019 年以来 5 日 IC 均值为 13.3%，10 日 IC 均值为 15.0%，多头组合超额收益为 49.0%，多头 IR 为 3.85。相比等权模型、树模型和网络模型，综合因子 IC 均值和多头超额收益均是最优。

表17： 综合因子绩效

年份	多空收益	多头超额	多头 IR	5 日 IC	10 日 IC
201901	136.0%	48.1%	7.81	15.3%	17.2%
2020	133.9%	56.9%	6.32	13.0%	14.4%
2021	129.9%	52.9%	3.63	12.0%	13.3%
2022	108.4%	48.1%	6.65	13.8%	15.9%
2023	85.2%	26.0%	3.71	12.2%	14.5%
2024	119.4%	47.4%	2.25	12.3%	13.3%
202506	68.0%	22.2%	7.13	16.2%	18.6%
period	123.6%	49.0%	3.85	13.3%	15.0%

数据来源：Wind，财通证券研究所

综合因子在核心成分中表现出较强选股能力，因子在沪深 300、中证 500、中证 1000 和国证 2000 指数成分股中多头组合超额收益年化值分别为 26.5%、22.7%、33.4%和 39.6%。

表18： 综合因子分域绩效

年份	沪深 300		中证 500		中证 1000		国证 2000	
	多头超额	IC	多头超额	IC	多头超额	IC	多头超额	IC
201901	37.4%	7.2%	33.8%	10.8%	50.9%	15.7%	43.9%	16.8%
2020	42.1%	8.8%	26.2%	9.9%	52.7%	12.8%	53.5%	14.4%
2021	29.6%	7.3%	41.8%	7.8%	43.9%	10.9%	50.0%	12.5%
2022	22.2%	8.0%	19.3%	8.7%	31.1%	11.8%	35.6%	13.9%
2023	27.6%	9.0%	13.7%	7.4%	20.2%	10.3%	17.2%	11.2%
2024	7.0%	5.9%	7.9%	5.3%	8.0%	6.7%	34.6%	11.3%
202506	4.1%	7.6%	5.4%	7.8%	9.6%	12.1%	14.3%	14.3%
period	26.5%	7.7%	22.7%	8.3%	33.4%	11.4%	39.6%	13.4%

数据来源：Wind，财通证券研究所

4 风险模型

相较于传统 barra 等风险模型基于投资逻辑构建一些风险因子，我们尝试用神经网络通过端到端学习模式直接从原始量价数据中识别高维非线性风险模式。基于神经网络提取风险信号与 alpha 信号的训练流程大体一致，差异在于两方面：

其一，风险模型目标在于解释股票收益截面差异，其预测目标为原始收益；而 Alpha 模型目标在于预测风格以外的股票特质收益，其预测目标为残差收益。因此，对于提取风险特征，我们将标签定义为： $label = close_{t+5}/close_t - 1$ 。

其二，风险模型追求解释能力最大化，而 Alpha 模型追求预测能力最大化。因此，对于提取风险特征，我们将损失函数定义为： $loss = abs(corr(pred, label))$ 。

考虑到网络训练出的风险特征中可能夹带 alpha 信息，我们将风险因子对于 Alpha 因子回归后，以残差值作为纯粹风险刻画。


表19： 风险因子绩效

年份	日线行情因子		分钟线行情因子	
	IC 均值	IC 均值	IC 均值	IC 均值
201901	-0.9%	13.9%	-3.1%	9.7%
2020	2.5%	15.2%	-1.9%	12.0%
2021	0.4%	14.5%	-1.5%	12.7%
2022	6.1%	17.0%	-4.0%	17.0%
2023	-1.9%	19.0%	1.9%	18.4%
2024	-1.3%	25.2%	0.0%	19.1%
202506	1.9%	24.8%	3.4%	22.0%
period	0.9%	17.9%	-1.1%	15.3%

数据来源：Wind，财通证券研究所

2019 年以来，基于日/分钟行情提取的风险因子 IC 均值长期在 0 附近，但|IC|均值超过 15%；IC 序列在 2024 年后的波动明显放大，表现出更强的解释能力。

图4： 风险因子 IC 序列



数据来源：Wind，财通证券研究所

5 指数增强组合

结合深度学习 alpha 模型和风险模型，我们通过组合优化构建组合：

$$\begin{aligned} \max: & r^T w \\ \text{s.t. } & s_l \leq w^T X - S_b \leq s_u \\ & h_l \leq w^T H - H_b \leq h_u \\ & \text{limitPos} \leq w^T M_b \leq 1 \\ & l_{b,i} \leq w_i \leq u_{b,i} \\ & \text{sum}(w) = 1 \end{aligned}$$

其中：

- r^T 为股票 alpha 得分， X 为股票风格暴露矩阵， H 为股票行业暴露矩阵；
- S_b 为基准风格暴露向量， H_b 为基准行业配置向量；
- w_i 为股票 i 权重， $l_{b,i}$ 、 $u_{b,i}$ 为权重约束上下限；
- M_b 为股票是否属于成分股 0-1 标记， limitPos 为组合在成分股中权重下限。

我们以综合信号作为 Alpha 得分，我们通过组合优化构建沪深 300、中证 500 和中证 1000 指数增强组合。

相较于以往“AI+量价”模型追求高换手，赚取市场中短期定价不充分的交易性机会，我们追求适配于机构投资者的低换手指增模型。

我们在构建 alpha 信号时使用了较长的预测窗口以及较长的回看周期，同时在量价信号提取过程中融合了基本面信息，这减缓了 alpha 信号的衰减。按照周度调仓标准，我们约束组合单周换手上限 10%，年单边换手率约 5.5 倍。


最终，组合中使用如下风控约束进行历史回溯：

- 交易费率：按照双边 0.3%计算交易成本；
- 指数成分权重下限：80%；
- 调仓周期：每周末得到持仓，按照周一均价撮合；
- 换手率约束：单次调仓约束单边 10%换手上限，年度单边换手率约 5.5 倍；
- 风格暴露：SIZE、AI 风险因子相对偏离上限 0.2，行业最大相对偏离上限 2%；
- 个股偏离：沪深 300 指数 1%，中证 500 指数 0.8%，中证 1000 指数 0.5%；

5.1 沪深 300 指数增强

基于深度学习框架，我们构建了沪深 300 指数增强组合。

图5： 沪深 300 增强组合净值



数据来源：Wind，财通证券研究所

2019 年以来，沪深 300 指数增强组合的年化收益为 18.2%，相对沪深 300 指数的年化超额收益为 14.2%；组合年化跟踪误差为 4.5%，信息比率为 2.84。

表20： 沪深 300 增强组合绩效


年份	组合收益	基准收益	超额收益	跟踪误差	信息比率	超额回撤
2019	43.6%	34.9%	8.6%	3.5%	1.76	-2.3%
2020	45.7%	27.2%	18.5%	3.9%	3.49	-1.4%
2021	7.9%	-5.2%	13.1%	5.5%	2.31	-6.4%
2022	-7.5%	-21.6%	14.1%	4.2%	3.93	-2.2%
2023	5.1%	-11.4%	16.4%	4.4%	3.86	-2.1%
2024	26.4%	14.7%	11.7%	5.4%	1.76	-4.4%
20250627	6.9%	-0.3%	7.2%	2.4%	2.88	-1.6%
全样本	18.2%	4.0%	14.2%	4.5%	2.84	-6.4%

数据来源：Wind，财通证券研究所

5.2 中证 500 指数增强

基于深度学习框架，我们构建了中证 500 指数增强组合。

图6： 中证 500 增强组合净值



数据来源：Wind，财通证券研究所

2019 年以来，中证 500 指数增强组合的年化绝对收益为 22.4%，相对中证 500 指数的年化超额收益为 17.2%；组合年化跟踪误差为 4.8%，信息比率为 3.16，历史相对最大回撤幅度为-5.3%。

表21： 中证 500 增强组合绩效


年份	组合收益	基准收益	超额收益	跟踪误差	信息比率	超额回撤
2019	43.7%	25.1%	18.6%	3.9%	3.56	-1.8%
2020	47.4%	20.9%	26.5%	4.3%	4.66	-3.1%
2021	47.4%	15.6%	31.9%	5.2%	4.67	-4.5%
2022	-9.5%	-20.3%	10.8%	4.4%	2.92	-2.1%
2023	7.2%	-7.4%	14.6%	4.4%	3.30	-2.2%
2024	14.7%	5.5%	9.2%	6.1%	1.36	-5.3%
20250627	6.7%	2.4%	4.3%	3.3%	1.21	-2.3%
全样本	22.4%	5.2%	17.2%	4.8%	3.16	-5.3%

数据来源：Wind，财通证券研究所

5.3 中证 1000 指数增强

基于深度学习框架，我们构建了中证 1000 指数增强组合。

图7： 中证 1000 增强组合净值



数据来源：Wind，财通证券研究所

2019 年以来，中证 1000 指数增强组合的年化绝对收益为 29.8%，相对中证 1000 指数的年化超额收益为 24.5%；组合年化跟踪误差为 5.4%，信息比率为 3.87，历史相对最大回撤幅度为-5.1%。

表22： 中证 1000 增强组合绩效

年份	组合收益	基准收益	超额收益	跟踪误差	信息比率	超额回撤
2019	57.0%	23.8%	33.2%	4.2%	5.61	-1.4%
2020	52.5%	19.4%	33.1%	4.7%	5.16	-1.9%
2021	58.5%	20.5%	38.0%	6.1%	4.46	-4.0%
2022	2.2%	-21.6%	23.8%	4.9%	5.34	-1.8%
2023	9.5%	-6.3%	15.8%	4.2%	3.72	-2.1%
2024	13.0%	1.2%	11.8%	7.0%	1.61	-5.1%
20250627	13.1%	5.4%	7.7%	4.5%	1.50	-2.7%
全样本	29.8%	5.3%	24.5%	5.4%	3.87	-5.1%

数据来源：Wind，财通证券研究所

6 风险提示

因子失效风险：选股因子有效性基于历史数据总结，未来存在失效风险；

模型失效风险：选股模型基于历史数据量化建模，未来存在失效风险；

市场风格变动风险：市场风格切换可能导致模型阶段性失效。

信息披露

● 分析师承诺

作者具有中国证券业协会授予的证券投资咨询执业资格，并注册为证券分析师，具备专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解。本报告清晰地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，作者也不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

● 资质声明

财通证券股份有限公司具备中国证券监督管理委员会许可的证券投资咨询业务资格。

● 公司评级

以报告发布日后 6 个月内，证券相对于市场基准指数的涨跌幅为标准：

买入：相对同期相关证券市场代表性指数涨幅大于 10%；

增持：相对同期相关证券市场代表性指数涨幅在 5%~10%之间；

中性：相对同期相关证券市场代表性指数涨幅在-5%~5%之间；

减持：相对同期相关证券市场代表性指数涨幅小于-5%；

无评级：由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级。

A 股市场代表性指数以沪深 300 指数为基准；中国香港市场代表性指数以恒生指数为基准；美国市场代表性指数以标普 500 指数为基准。

● 行业评级

以报告发布日后 6 个月内，行业相对于市场基准指数的涨跌幅为标准：

看好：相对表现优于同期相关证券市场代表性指数；

中性：相对表现与同期相关证券市场代表性指数持平；

看淡：相对表现弱于同期相关证券市场代表性指数。

A 股市场代表性指数以沪深 300 指数为基准；中国香港市场代表性指数以恒生指数为基准；美国市场代表性指数以标普 500 指数为基准。

● 免责声明

本报告仅供财通证券股份有限公司的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本报告的信息来源于已公开的资料，本公司不保证该等信息的准确性、完整性。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的邀请或向他人作出邀请。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

本公司通过信息隔离墙对可能存在利益冲突的业务部门或关联机构之间的信息流动进行控制。因此，客户应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司不对任何人使用本报告中的任何内容所引致的任何损失负任何责任。

本报告仅作为客户作出投资决策和公司投资顾问为客户提供投资建议的参考。客户应当独立作出投资决策，而基于本报告作出任何投资决定或就本报告要求任何解释前应咨询所在证券机构投资顾问和服务人员的意见；

本报告的版权归本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。